BDM – approfondimento sperimentale – fase 2

Obiettivo: prendere confidenza con

- riduzione della dimensionalita',
- apprendimento non supervisionato, e
- serie temporali.

Costruiremo sui risultati conseguiti nella fase 1 della sperimentazione.

Considerando i dati messi a vostra disposizione:

• Task 0a: Scrivere un programma che crei un dizionario di "gesture words":

Data una cartella di gesti contenente le sottocartelle X, Y, Z, e W, una lunghezza di finestra w, una lunghezza di shift, s, e una risoluzione r,

- 1. per ciascun file di dati, fi, il programma crea un file fi.wrd contenente quanto segue:
- (a) per ciascuna componente $ci \in \{X, Y, Z, W\}$
- i. scrive in output l'identificatore della componente, cl;
- ii. per ciascun sensore si di finella componene ci,
- A. scrive nel file di output l'identificatore del sensore si,
- B. calcola e scrive nel file di output, l'ampiezza media, avgi, dei valori,
- C. calcola e scrive nel file di output, le deviazioni standard, stdi, , of the values,
- D. normalizza i valori riconducendoli all'intervallo tra -1.0 e1.0 (se i valori sono tutti uguali, allora vengono normalizzati a 0.0)
- E. quantizza i valori in 2r levelli, come descritto della Fase1 del progetto,
- F. sposta una finestra di lunghezza w sulla corrispondente serie temporale (facendo scorrere in avanti l'inizio della finestra di s istanti temporali per volta), e alla posizione h
- $G.\ calcola\ e\ scrive\ nel\ file\ di\ output,\ l'ampiezza\ quantizzata\ media,\ avgQ_{i,j,h},\ per\ la\ finestra\ h\ \ del\ sensore\ s_j$
- $H. \ calcola \ e \ scrive \ nel \ file \ di \ output, \ il \ descrittore \ simbolico \ della \ finestra \ quantizzata, \ win Q_{i,j,h} \ per \ la \ finestra \ h \ del \ sensore \ s_j$

IMPORTANTE: Per i tasks successivi, il dizionario delle parole consiste di h triple < Component_Name, sensor ID, winQ>

- Task 0b: Scrivere un programma che, data una directory, dir, associ a ciascun sensore s_j in ciascun file di gesti fi due vettori di gesti, sulla base dei
- valori TF (i risultati per tutti i sensori per il dato gesto sono scritti in un unico file di output, tf vectors fi.txt)
- valori TF-IDF (i risultati per tutti i sensori per il dato gesto sono scritti in un unico file di output, tfidf vectors fi.txt)
- Task 1 Scrivere un programma che, dato un insieme di file di gesti, un modello vettoriale scelto dall'utente, e un valore k, identifichi e restituisca le top-k semantiche latenti/topics, utilizzando
- opzione #1: PCA,
- opzione #2: SVD,
- opzione #3: LDA.

Potete usare i packages Matlab per calcolare queste semantiche. I topic latenti vanno presentati nella forma di coppie <parola, score> ordinate secondo l'ordine non crescente degli score.

- Task 2: Scrivere un programma che, dato un file di gesti, individui i 10 gesti piu' simili nel database di gesti, utilizzado:
- opzione #1: dot product di vettori di gesti,
- opzione #2, 3, 4: top-k semantiche latenti dei sensori (PCA, SVD, LDA),
- opzione #5: edit distance sui descrittori simbolici delle finestre quantizzati (proporre una funzione di costo di edit tra i simboli),
- user option #6: distanza DTW sulle ampiezze quantizzate medie

I risultati vanno presentati nella forma di coppie <gesture, score> ordinate secondo l'ordine non crescente degli score di somiglianza.

- Task 3: scoperta di Gesture Latenti: scrivere un programma che, dato un valore p,
- 1. crei una matrice di similarita' gesture-gesture, utilizzando
- * opzione #1: dot product di vettori dei gesti,

- * opzioni #2, 3, 4: top-k semantiche dei sensori latenti (PCA, SVD, LDA),
- * opzione #5: edit distance sui descrittori simbolici delle finestre quantizzati (proporre una funzione di costo di edit tra i simboli),
- * opzione #6: distanza DTW sulle ampiezze quantizzate medie
- 2. calcoli SVD su questa matrice di similarita' gesture-gesture matrix, e
- 3. restituisca le top-p componenti principali (in termini di appartenenza dei gesti) sottostanti questa matrice di similarita' gesture-gesture

I risultati vanno presentati nella forma di coppie <gesture, score> ordinate secondo l'ordine non crescente degli score di appartenenza.

- Task 4: Analisi e Clustering di Gesti latenti
- Task 4a:Scrivere un programma che consideri le top-p semantiche latent dei gesti ottenuti al task 3 e partizioni i gesti in p gruppi in base ai loro gradi di appartenenza alle p semantiche.
- Task 4b:

scrivere un programma che consideri la matrice di similarita' gesture-gesture ottenuta utilizzando

- * opzione #1: dot product di vettori dei gesti,
- * opzioni #2, 3, 4: top-k semantiche dei sensori latenti (PCA, SVD, LDA),
- * opzione #5: edit distance sui descrittori simbolici delle finestre quantizzati (proporre una funzione di costo di edit tra i simboli),
- * opzione #6: distanza DTW sulle ampiezze quantizzate medie

e clusterizzi i gesti in p gruppi utilizzando un algoritmo basato su k-means (preferibilmente un algoritmo implementato da voi, non da libreria).

- Task 4c: scrivere un programma che consideri la matrice di similarita' gesture-gesture ottenuta utilizzando
- 1. crei una matrice di similarita' gesture-gesture, utilizzando
- * opzione #1: dot product di vettori dei gesti,
- * opzioni #2, 3, 4: top-k semantiche dei sensori latenti (PCA, SVD, LDA),
- * opzione #5: edit distance sui descrittori simbolici delle finestre quantizzati (proporre una funzione di costo di edit tra i simboli),
- * opzione #6: distanza DTW sulle ampiezze quantizzate medie

e clusterizzi i gesti in p groups utilizzando una tecnica di clustering spettrale basato sulla matrice Laplaciana.

- Task 5: classificazione di gesti. Implementare:
- un algoritmo di classificazione basato su k-nearest neighbor, e
- un algoritmo di classificazione basato su decision tree

che ricevano in input un insieme di gesti etichettati ed associno un'etichetta ai rimanenti gesti del database.